

**TRƯỜNG ĐẠI HỌC CÔNG NGHỆ KỸ THUẬT
THÀNH PHỐ HỒ CHÍ MINH**

HỌC PHẦN: TRÍ TUỆ NHÂN TẠO CHO IoT

ĐỀ CƯƠNG TIỂU LUẬN CUỐI KHÓA

**HỌC ĐA NHIỆM TRÊN CIFAR-10:
PHÂN LOẠI SIÊU LỚP KẾT HỢP
DỰ ĐOÁN GÓC XOAY ẢNH TỰ GIÁM SÁT**

Đánh giá trong điều kiện hạn chế nhận huấn luyện

Mã đề tài:	M8
Sinh viên:	Đình Xuân Huy
MSSV:	23110102
Phân nhóm:	Đa nhiệm
Dữ liệu:	CIFAR-10
Lớp học phần:	Trí tuệ nhân tạo cho IoT
Giảng viên hướng dẫn:	
Năm học:	2026–2027

Phiên bản chỉnh sửa học thuật

Thành phố Hồ Chí Minh, 2026

1. Đặt vấn đề và mục tiêu

1.1. Đặt vấn đề

Đề tài khảo sát học đa nhiệm (Multi-task Learning) cho bài toán phân loại ảnh CIFAR-10 thành hai siêu lớp do đề tài quy ước: Animal và Vehicle. Mô hình dùng chung một bộ trích xuất đặc trưng ResNet-18, đồng thời học nhiệm vụ chính là phân loại siêu lớp và nhiệm vụ phụ là dự đoán phép xoay đã áp dụng lên ảnh. Nhãn của nhiệm vụ phụ được tạo tự động từ phép biến đổi, không cần nhãn ngữ nghĩa của ảnh [1], [2].

Động cơ nghiên cứu là đánh giá khả năng khai thác tín hiệu tự giám sát khi số ảnh có nhãn dùng cho huấn luyện bị giới hạn. Nhiệm vụ dự đoán góc xoay được vận dụng từ hướng nghiên cứu RotNet; đề tài không xem việc ghép ResNet-18 với hai đầu ra là một kiến trúc mới. Góc xoay ở đây là góc biến đổi nhân tạo, không phải góc tư thế thực của đối tượng trong ảnh [2].

Ở cấu hình sử dụng thêm ảnh không nhãn, đây là thiết lập học bán giám sát với một nhiệm vụ phụ tự giám sát. Thuật ngữ “học đa nhiệm” mô tả giai đoạn huấn luyện; khi suy luận chỉ giữ nhiệm vụ phân loại Animal/Vehicle. Vì vậy, lợi ích cần kiểm chứng là chất lượng phân loại, không phải mặc nhiên giảm chi phí suy luận so với mô hình đơn nhiệm có cùng backbone.

1.2. Mục tiêu và câu hỏi nghiên cứu

Mục tiêu tổng quát: xây dựng và đánh giá một quy trình thực nghiệm có thể tái lập để xác định ảnh hưởng của nhiệm vụ dự đoán góc xoay đối với phân loại siêu lớp tại các mức 10%, 20% và 50% nhãn huấn luyện.

Câu hỏi	Nội dung đánh giá
C1. Hiệu quả phân loại	M8 có thay đổi Macro-F1 và Accuracy so với baseline chỉ học phân loại siêu lớp trong cùng ngân sách nhãn hay không?
C2. Vai trò của dữ liệu	Kết quả khác nhau thế nào khi nhánh rotation chỉ dùng ảnh thuộc tập có nhãn và khi được dùng toàn bộ tập train?
C3. Chi phí thực hiện	Chi phí huấn luyện tăng bao nhiêu; mô hình một đầu ra khi suy luận có số tham số, dung lượng và độ trễ như thế nào trên máy đo xác định?

Giả thuyết cần kiểm chứng: nhiệm vụ phụ có thể cải thiện kết quả, đặc biệt khi ít nhãn. Đề tài vẫn phải báo cáo đầy đủ trường hợp không cải thiện hoặc suy giảm; không đặt yêu cầu kết quả của M8 bắt buộc cao hơn baseline.

1.3. Phạm vi

Giữ nguyên CIFAR-10, ResNet-18 điều chỉnh cho ảnh 32×32 và thời gian dự kiến bốn tuần. Phần bắt buộc tập trung vào baseline và M8; Contrastive Learning/SupCon là mở rộng tùy chọn. Đánh giá chi phí suy luận phục vụ thảo luận về Edge AI, không thay thế thử nghiệm trên thiết bị IoT thực tế và không mặc nhiên chứng minh khả năng triển khai trên vi điều khiển.

2. Tập dữ liệu và tiền xử lý

2.1. Dữ liệu và ánh xạ nhãn

CIFAR-10 gồm 60.000 ảnh RGB kích thước 32×32 : 50.000 ảnh train chính thức và 10.000 ảnh test chính thức; mỗi lớp gốc có 5.000 ảnh train và 1.000 ảnh test [5]. Hai siêu lớp dưới đây là phép gộp của đề tài, không phải bộ nhãn siêu lớp chính thức của CIFAR-10.

Nhãn mới	Siêu lớp	Các lớp gốc
0	Animal	bird, cat, deer, dog, frog, horse
1	Vehicle	airplane, automobile, ship, truck

Theo thứ tự nhãn gốc của CIFAR-10, Animal = {2, 3, 4, 5, 6, 7}; Vehicle = {0, 1, 8, 9}. Sau ánh xạ, tỷ lệ Animal/Vehicle là 60%/40%, không còn cân bằng. Vì vậy, Macro-F1 là chỉ số chính; Accuracy là chỉ số bổ sung.

2.2. Chia dữ liệu và ngân sách nhãn

Dùng seed 2026 để chia 50.000 ảnh train thành 45.000 ảnh trong tập huấn luyện D_{train} và 5.000 ảnh validation D_{val} , phân tầng theo 10 lớp gốc. Tập test chính thức D_{test} được giữ riêng. Trong mỗi lần lặp $s \in \{42, 43, 44\}$, tạo một thứ tự ngẫu nhiên theo từng lớp gốc rồi lấy các tập có nhãn lồng nhau $D_{L,10\%} \subset D_{L,20\%} \subset D_{L,50\%}$.

Tỷ lệ	Có nhãn D_L	Animal	Vehicle	Ấn nhãn D_U
10%	4.500	2.700	1.800	40.500
20%	9.000	5.400	3.600	36.000
50%	22.500	13.500	9.000	22.500

Bảng 1. Số ảnh huấn luyện theo tỷ lệ nhãn; $D_U = D_{train} \setminus D_L$.

Mỗi mức tỷ lệ được tính trên 45.000 ảnh train, không phải trên toàn bộ 60.000 ảnh. D_{val} có 3.000 ảnh Animal và 2.000 ảnh Vehicle; D_{test} có lần lượt 6.000 và 4.000 ảnh. Ngoài nhãn huấn luyện, 5.000 nhãn validation được dùng để chọn checkpoint và phải khai báo riêng khi thảo luận mức độ tiết kiệm nhãn.

Nhãn gốc chỉ phục vụ chuẩn bị phép chia benchmark; không được đưa nhãn thật của D_U vào loss, chọn positive pair, huấn luyện bộ phân loại hoặc lựa chọn mô hình. Lưu chỉ mục của tất cả tập; kiểm tra không trùng chỉ mục giữa train, validation và test. Validation/test không tham gia huấn luyện, kể cả qua nhánh tự giám sát.

2.3. Tiền xử lý và sinh nhãn góc xoay

Nhánh phân loại: RandomCrop(32, padding=4), RandomHorizontalFlip($p=0.5$), chuyển về tensor [0,1], sau đó Normalize với mean = std = (0,5; 0,5; 0,5). Đây là hằng số được chọn trước, áp dụng chung cho mọi cấu hình, không ước lượng từ validation/test.

Nhánh rotation: dùng ảnh gốc 32×32 , chọn k đều trong $\{0,1,2,3\}$, áp dụng R_k = xoay $90k$ độ ngược chiều kim đồng hồ bằng torch.rot90; sau đó chuẩn hóa như trên [10]. Không thêm phép xoay hoặc lật sau bước gán k . Validation/test của nhiệm vụ chính chỉ chuyển tensor và chuẩn hóa, không augmentation ngẫu nhiên.

3. Phương pháp đề xuất

3.1. Kiến trúc học đa nhiệm

Dùng ResNet-18 khởi tạo ngẫu nhiên, không dùng trọng số tiền huấn luyện. Thay convolution đầu bằng Conv2d(3,64,kernel_size=3,stride=1,padding=1,bias=False), bỏ MaxPool đầu mạng và giữ bốn nhóm residual block, mỗi nhóm hai BasicBlock [1], [6].

Thành phần	Kích thước đầu ra C × H × W
Ảnh đầu vào	3 × 32 × 32
Conv 3 × 3 + BatchNorm + ReLU	64 × 32 × 32
Nhóm residual 1: 2 BasicBlock	64 × 32 × 32
Nhóm residual 2: 2 BasicBlock	128 × 16 × 16
Nhóm residual 3: 2 BasicBlock	256 × 8 × 8
Nhóm residual 4: 2 BasicBlock	512 × 4 × 4
Global Average Pooling + Flatten	Vector 512 chiều
Hai đầu ra tuyến tính, có bias	Superclass: 512 → 2; Rotation: 512 → 4

Ký hiệu f_θ là encoder dùng chung; g_{sup} và g_{rot} là hai head; N là bước chuyển tensor và chuẩn hóa. Hai nhánh nhận các view khác nhau, không giả định cùng một vector đặc trưng cho ảnh chuẩn và ảnh đã xoay.

$$a_{\text{sup}} = g_{\text{sup}}(f_\theta(t_{\text{sup}}(x))) \in \mathbb{R}^2$$

$$a_{\text{rot}} = g_{\text{rot}}(f_\theta(N(R_k(x)))) \in \mathbb{R}^4$$

Khi huấn luyện M8, ghép hai minibatch theo chiều batch trước khi qua encoder, sau đó tách đặc trưng về đúng head; các lớp BatchNorm dùng chung. Khi suy luận, chỉ chạy encoder và Superclass Head; chọn lớp bằng argmax của hai logits, không cần Rotation Head.

3.2. Hàm mất mát và cách sử dụng dữ liệu

Với B_L là minibatch có nhãn, B_R là minibatch cho nhiệm vụ xoay và b_L , b_R là số mẫu tương ứng, hai mất mát được lấy trung bình riêng:

$$L_{\text{sup}} = \frac{1}{b_L} \sum_{i=1}^{b_L} \text{CE}(a_{\text{sup},i}, y_i)$$

$$L_{\text{rot}} = \frac{1}{b_R} \sum_{j=1}^{b_R} \text{CE}(a_{\text{rot},j}, k_j)$$

$$L = L_{\text{sup}} + \lambda_{\text{rot}} L_{\text{rot}}$$

CE là cross-entropy cho nhãn lớp nguyên. Trong PyTorch, truyền logits trực tiếp vào CrossEntropyLoss, không áp dụng Softmax trước loss [7]. Chỉ ảnh thuộc D_L đóng góp vào L_{sup} ; B_R lấy từ D_L hoặc D_{train} tùy cấu hình. Chốt $\lambda_{\text{rot}} = 0,5$ cho thí nghiệm chính; các giá trị khác chỉ thuộc khảo sát độ nhạy đã khai báo.

3.3. Mở rộng Contrastive Learning và SupCon

Nội dung này được giữ như hướng mở rộng, không phải điều kiện hoàn thành đề tài. Chỉ triển khai sau khi có kết quả đầy đủ của phần chính; ưu tiên một nhánh mở rộng thay vì đồng thời chạy toàn bộ E3–E6.

Contrastive Learning tự giám sát: tạo hai view của cùng một ảnh và đưa qua encoder cùng Projection Head; hai view này tạo positive pair. Có thể dùng ảnh từ D_{train} vì không cần nhãn siêu lớp. Trường hợp tham khảo SimCLR phải xác định rõ loss NT-Xent, chuẩn hóa vector, nhiệt độ, phép tăng cường ảnh, kích thước batch và chiều Projection Head [3].

Supervised Contrastive Learning (SupCon): xây dựng positive pair từ các view có cùng nhãn siêu lớp đã được cấp cho huấn luyện. Trong đề tài này, SupCon chỉ sử dụng D_L ; không được đọc nhãn thật của D_U . SupCon là học có giám sát, không được gọi là một nhiệm vụ tự giám sát [4].

ID tùy chọn	Hàm mục tiêu	Nguồn dữ liệu cho loss bổ sung
E3	$L_{\text{sup}} + \lambda_c L_{\text{NT-Xent}}$	D_{train} ; không dùng nhãn siêu lớp
E4	$L_{\text{sup}} + \lambda_c L_{\text{SupCon}}$	Chỉ D_L có nhãn hợp lệ
E5	$L_{\text{sup}} + \lambda_{\text{rot}} L_{\text{rot}} + \lambda_c L_{\text{NT-Xent}}$	Rotation và NT-Xent: D_{train}
E6	$L_{\text{sup}} + \lambda_{\text{rot}} L_{\text{rot}} + \lambda_c L_{\text{SupCon}}$	Rotation: D_{train} ; SupCon: D_L

Các cấu hình trên là biến thể đồng huấn luyện của đề tài, không mặc nhiên là tái lập nguyên trạng quy trình của SimCLR hoặc SupCon. Projection Head chỉ dùng khi huấn luyện; việc bỏ head này không loại bỏ chi phí tăng thêm trong quá trình học. Mọi siêu tham số mở rộng phải được khóa bằng validation trước khi đánh giá test.

3.4. Baseline và đối chứng bắt buộc

ID	Cấu hình	Ảnh cho phân loại	Ảnh cho rotation
E1	Baseline chỉ học siêu lớp	D_L	Không có
E2-L	M8 dùng cùng tập ảnh nguồn	D_L	Chỉ D_L
E2	M8 có thêm ảnh ẩn nhãn	D_L	$D_{\text{train}} = D_L \cup D_U$

Bảng 2. Ba cấu hình chính; E2-L là đối chứng được bổ sung.

So sánh E2-L với E1 đánh giá tác động của việc bổ sung nhánh rotation khi không mở rộng tập ảnh nguồn. So sánh E2 với E2-L đánh giá ảnh hưởng của việc mở rộng nguồn ảnh cho nhánh phụ. So sánh E2 với E1 đánh giá hiệu quả tổng thể của M8 trong cùng ngân sách nhân.

Các so sánh được ghép cặp theo lần lặp và tỷ lệ nhân. E2-L/E2 vẫn xử lý thêm view và thay đổi thống kê BatchNorm so với E1; do đó không diễn giải chúng là phép tách hoàn toàn riêng tác dụng của nhân góc xoay khỏi mọi thay đổi về tính toán. Không khẳng định so sánh công bằng về FLOPs hoặc thời gian chỉ vì cùng số epoch.

4. Thiết kế thực nghiệm và chỉ số

4.1. Cấu hình huấn luyện

Thành phần	Thiết lập cho thí nghiệm chính
Môi trường	PyTorch; ghi rõ Python, PyTorch, TorchVision, CUDA/cuDNN (nếu có), CPU/GPU và RAM/VRAM thực tế.
Khởi tạo	Ngẫu nhiên; mỗi cặp so sánh dùng cùng trọng số khởi tạo của encoder và Superclass Head.
Optimizer	AdamW; learning rate 3×10^{-4} ; weight decay 10^{-4} ; betas=(0.9, 0.999); eps= 10^{-8} .
Minibatch	B_L tối đa 128 ảnh. Với E2-L/E2, B_R có cùng số ảnh với B_L tại mỗi bước; một góc xoay ngẫu nhiên trên mỗi ảnh.
Ngân sách học	100 epoch; một epoch là một lượt duyệt D_L. Giữ minibatch cuối nhỏ hơn 128, không bỏ mẫu.
Scheduler	CosineAnnealingLR, T_max=100, eta_min=0; cập nhật sau mỗi epoch.
Chọn checkpoint	Macro-F1 validation cao nhất; nếu bằng nhau, ưu tiên loss phân loại validation thấp hơn, sau đó epoch sớm hơn.
Ngẫu nhiên	Ba lần lặp s = 42, 43, 44; lưu seed của subset, khởi tạo, DataLoader và augmentation [9].

Để thống nhất số bước cập nhật có giám sát, không dùng Early Stopping trong bảng kết quả chính. Cả ba cấu hình chạy cùng 100 epoch và đều được phép chọn checkpoint bằng cùng tiêu chí validation. Early Stopping patience=10 của bản ban đầu chỉ có thể dùng cho thử nghiệm thăm dò và phải ghi rõ, không trộn vào so sánh chính.

4.2. Quy trình và nguyên tắc so sánh

Trong mỗi epoch, duyệt D_L một lần với cùng chuỗi minibatch có giám sát cho các cấu hình ghép cặp. Với mỗi bước của M8, lấy B_R ngẫu nhiên từ nguồn ảnh quy định tại Bảng 2; dùng một bộ sinh số ngẫu nhiên độc lập để việc lấy ảnh/góc xoay không làm thay đổi augmentation của nhánh phân loại. Tính tổng loss rồi thực hiện một bước optimizer.

E1 không chạy nhánh rotation, kể cả forward. Đặt $\lambda_{\text{rot}}=0$ nhưng vẫn đưa ảnh xoay qua BatchNorm không được xem là baseline E1 vì thống kê chạy của mạng vẫn có thể bị thay đổi. Với mọi cấu hình, không dùng nhãn của D_U để phân tầng minibatch huấn luyện hoặc xây dựng mục tiêu học.

Khối thực nghiệm chính gồm 3 cấu hình $\times$ 3 mức nhãn $\times$ 3 lần lặp = 27 lượt huấn luyện. Ba lần lặp thay đổi subset có nhãn và ngẫu nhiên huấn luyện, trong khi phép chia train/validation/test được cố định; đây không phải cross-validation. Báo cáo thời gian huấn luyện, số bước và số lượt ảnh được xử lý cho từng cấu hình.

Khảo sát tùy chọn: $\lambda_{\text{rot}} \in \{0,1; 0,25; 0,5; 1,0\}$ tại mức 10% nhãn, ưu tiên trước các mở rộng E3–E6. Giữ $\lambda_{\text{rot}}=0,5$ cho so sánh chính; không lựa chọn λ hoặc cấu hình dựa trên test. Nếu tài nguyên không đủ, phải điều chỉnh ngân sách chung và ghi nhận trước khi mở kết quả test.

4.3. Chỉ số và cách báo cáo

Chỉ số chính là Macro-F1 của Animal và Vehicle. Báo cáo thêm Accuracy, precision/recall/F1 từng lớp và ma trận nhầm lẫn trên toàn bộ 10.000 ảnh test. Mỗi ảnh chỉ cho một dự đoán của nhánh siêu lớp; không dùng test-time augmentation trong thí nghiệm chính.

$$\text{Accuracy} = \frac{1}{N} \sum_{i=1}^N 1(\hat{y}_i = y_i)$$

$$P_c = \frac{TP_c}{TP_c + FP_c}; R_c = \frac{TP_c}{TP_c + FN_c}$$

$$F1_c = \frac{2 P_c R_c}{P_c + R_c}; \text{Macro-F1} = \frac{F1_{\text{Animal}} + F1_{\text{Vehicle}}}{2}$$

Nếu mẫu số của precision/recall/F1 bằng 0, quy ước giá trị đó bằng 0 và dùng thống nhất. Tính chỉ số từ toàn bộ dự đoán của tập đánh giá, không lấy trung bình không trọng số các F1 của từng minibatch. Bộ phân loại luôn đoán Animal đạt Accuracy 60% trên phép chia này, nên Accuracy đơn lẻ chưa phản ánh đầy đủ chất lượng hai lớp.

Báo cáo trung bình $\pm$ độ lệch chuẩn mẫu qua ba lần lặp và chênh lệch ghép cặp $\Delta_s = \text{Macro-F1}_s(\text{M8}) - \text{Macro-F1}_s(\text{E1})$, tính bằng điểm phần trăm. Mức 10% là so sánh ưu tiên; 20% và 50% dùng đánh giá xu hướng. Ba lần lặp chỉ cho bằng chứng ban đầu về độ ổn định; không tự kết luận “có ý nghĩa thống kê” hoặc “luôn tốt hơn” từ một lần chạy tốt nhất.

Rotation Accuracy chỉ là chỉ số chẩn đoán nhánh phụ. Nếu đo trên validation, đánh giá đủ bốn phép xoay cho mỗi ảnh và ghi rõ giao thức; độ chính xác cao ở nhiệm vụ phụ không thay thế bằng chứng cải thiện Macro-F1 của nhiệm vụ chính.

4.4. Chi phí suy luận và giới hạn kết luận về IoT

Đếm riêng số tham số khi huấn luyện và khi suy luận; đo dung lượng tệp chỉ chứa trọng số suy luận, không gộp optimizer state. Với cấu hình tại mục 3.1, mô hình suy luận có 11.169.858 tham số; Rotation Head thêm 2.052 tham số. Phần tham số FP32 của mô hình suy luận tương đương khoảng 42,61 MiB, chưa gồm buffer, activation và bộ nhớ của runtime [6]. Đây là thông số kiến trúc, không phải kết quả huấn luyện.

Đo latency với batch=1, tensor $1 \times 3 \times 32 \times 32$, FP32, model.eval() và inference_mode(). Dùng cùng máy, runtime và số luồng CPU; chạy khởi động 50 lượt, sau đó đo tối thiểu 1.000 lượt trên cùng các ảnh validation đã tiền xử lý. Nếu đo GPU, đồng bộ trước/sau khối tính thời gian. Báo cáo mean, median, p95 theo ms/ảnh, lặp ba phiên và lưu log [8].

Phép đo trên chỉ tính thời gian suy luận của mô hình; phải tách riêng thời gian đọc ảnh, tiền xử lý và truyền dữ liệu. Hai mô hình E1/M8 có cùng kiến trúc suy luận, nên không kỳ vọng giảm độ phức tạp kiến trúc chỉ nhờ bỏ head phụ. Kết quả trên CPU máy tính chỉ là benchmark trên CPU đó; chỉ kết luận khả năng triển khai thiết bị biên khi đã đo trên thiết bị đích. Không suy diễn thành khả năng chạy trên vi điều khiển từ số tham số hoặc latency máy tính.

5. Kế hoạch thực hiện và bàn giao

5.1. Kế hoạch dự kiến trong bốn tuần

Tuần	Công việc	Mốc kiểm tra
1	Chuẩn bị dữ liệu; kiểm tra ánh xạ nhãn; tạo và lưu split/subset; cài E1; kiểm tra shape và đếm tham số. Chạy thử để ước lượng thời gian/GPU cần thiết.	Không trùng split; tỷ lệ nhãn đúng Bảng 1; baseline chạy được và có log validation.
2	Cài nhánh rotation, kiểm tra quy ước k và công thức loss; chạy E2-L/E2 ở mức 10%; kiểm tra nhãn ẩn không đi vào mục tiêu học.	Chốt mã nguồn và cấu hình chính; không mở test để chọn phương pháp.
3	Hoàn thành ba mức nhãn và ba lần lặp cho E1, E2-L, E2. Khảo sát λ trước; chỉ làm một mở rộng contrastive nếu còn tài nguyên.	Đủ kết quả phần chính hoặc ghi rõ lượt còn thiếu; lưu checkpoint, cấu hình, thời gian và log.
4	Khóa toàn bộ lựa chọn; đánh giá test; tổng hợp chỉ số ghép cặp; đo chi phí suy luận; phân tích lỗi; hoàn thiện báo cáo và gói tái lập.	Có bảng kết quả thực, phân tích giới hạn và hướng dẫn chạy lại từ dữ liệu gốc.

Tiến độ phụ thuộc máy huấn luyện thực tế. Không lấy việc giảm số lần lặp hoặc bỏ đối chứng mà không công bố để thay cho giới hạn tài nguyên; ưu tiên hoàn thành phần chính trước các mở rộng.

5.2. Sản phẩm bàn giao

Báo cáo kỹ thuật 15–25 trang, trình bày bài toán, dữ liệu, phương pháp, giao thức, kết quả, phân tích sai số và giới hạn. Bảng kết quả phải ghi cấu hình, tỷ lệ nhãn, số lần lặp, Macro-F1/Accuracy trung bình $\pm$ độ lệch chuẩn, thời gian huấn luyện và các thông số suy luận đã đo.

Mã nguồn gồm các bước chuẩn bị dữ liệu, huấn luyện, đánh giá và benchmark; kèm README, tệp cấu hình, môi trường/phần mềm, seed, danh sách chỉ mục split/subset và định nghĩa ánh xạ nhãn. Đóng gói checkpoint được chọn bằng validation cho các lượt chính; kèm logits hoặc dự đoán test theo chỉ mục để kiểm tra lại chỉ số.

Log huấn luyện phải thể hiện loss từng nhánh, chỉ số validation, checkpoint được chọn và chi phí thực tế. Hình/bảng tối thiểu gồm: luồng huấn luyện và suy luận; đường học train/validation; Macro-F1 theo tỷ lệ nhãn; bảng E1/E2-L/E2; ma trận nhầm lẫn và một số trường hợp dự đoán sai. Không đưa số liệu minh họa vào vị trí kết quả thực nghiệm.

5.3. Tiêu chí hoàn thành và giới hạn nghiên cứu

Hoàn thành khi xây dựng đúng quy trình, kiểm tra được việc tách dữ liệu và che nhãn, thực hiện đối chứng, báo cáo trung thực các lượt chạy và cung cấp mã nguồn tái lập. Kết quả âm hoặc không cải thiện vẫn phải được phân tích; không phải lý do sửa mục tiêu sau khi thấy test.

Kết luận chỉ áp dụng cho phép gộp hai siêu lớp, các tỷ lệ nhãn và giao thức đã khảo sát. Không so sánh trực tiếp Accuracy hai lớp với bảng xếp hạng CIFAR-10 mười lớp; không khẳng định đặc trưng tổng quát tốt hơn, thuật toán mới, tối ưu năng lượng hoặc hệ thống IoT hoàn chỉnh khi chưa có thí nghiệm tương ứng.

6. Tài liệu tham khảo

[1] K. He, X. Zhang, S. Ren và J. Sun, “Deep Residual Learning for Image Recognition,” Proceedings of CVPR, 2016, tr. 770–778.

[Bản tác giả trên arXiv](#)

[2] S. Gidaris, P. Singh và N. Komodakis, “Unsupervised Representation Learning by Predicting Image Rotations,” ICLR, 2018.

[Bản tác giả trên arXiv](#)

[3] T. Chen, S. Kornblith, M. Norouzi và G. Hinton, “A Simple Framework for Contrastive Learning of Visual Representations,” Proceedings of ICML, PMLR 119, 2020, tr. 1597–1607.

[Kỷ yếu PMLR](#)

[4] P. Khosla và cộng sự, “Supervised Contrastive Learning,” Advances in Neural Information Processing Systems, tập 33, 2020, tr. 18661–18673.

[Kỷ yếu NeurIPS](#)

[5] A. Krizhevsky, “Learning Multiple Layers of Features from Tiny Images,” University of Toronto, 2009. Thông tin cấu trúc và phân bố lớp tham chiếu trang CIFAR-10/CIFAR-100 của nhóm tác giả.

[Trang dữ liệu gốc](#)

[6] PyTorch Contributors, “resnet18” và “torchvision.models.resnet,” tài liệu và mã nguồn TorchVision.

[Tài liệu kiến trúc ResNet](#)

[7] PyTorch Contributors, “CrossEntropyLoss,” PyTorch 2.10 Documentation.

[Tài liệu loss chính thức](#)

[8] PyTorch Contributors, “PyTorch Benchmark,” PyTorch Tutorials.

[Hướng dẫn benchmark chính thức](#)

[9] PyTorch Contributors, “Reproducibility,” PyTorch 2.10 Documentation.

[Hướng dẫn tái lập chính thức](#)

[10] PyTorch Contributors, “torch.rot90,” PyTorch 2.10 Documentation.

[Tài liệu phép xoay chính thức](#)

Các nguồn trực tuyến được đối chiếu ngày 22/09/2026. Phiên bản phần mềm thực sự dùng để huấn luyện và đo thời gian phải được ghi theo môi trường thực nghiệm, không suy ra từ phiên bản của trang tài liệu.

PHỤ LỤC. ĐỐI CHIẾU CÁC CHỈNH SỬA HỌC THUẬT

Phụ lục này phân biệt nội dung của bản gốc với những điều chỉnh được đề xuất. Giữ nguyên thông tin sinh viên, mã M8, dữ liệu, hướng ResNet-18 đa nhiệm, sáu mục chính và kế hoạch bốn tuần. Không bổ sung kết quả Accuracy, Macro-F1 hoặc latency chưa đo.

Vị trí trong PDF gốc	Nội dung cần làm rõ	Điều chỉnh trong bản sửa
Trang 2, mục 1	Chỉ tiêu “phải không thấp hơn baseline” đặt trước kết quả mong muốn.	Chuyển thành giả thuyết kiểm chứng; ghi nhận cả kết quả âm và mức độ bất định.
Trang 2, mục 2	Tỷ lệ nhãn và việc dùng ảnh không nhãn chưa được đặc tả đủ.	Định nghĩa D_L/D_U, số lượng chính xác, subset lồng nhau; công khai 5.000 nhãn validation và việc che nhãn thật.
Trang 2 và 4	Hai siêu lớp có tỷ lệ 60/40 nhưng Accuracy là chỉ số chính.	Chọn Macro-F1 chính, kèm Accuracy, chỉ số từng lớp và ma trận nhầm lẫn.
Trang 3, Hình 1	Sơ đồ một input/hai head có thể khiến người đọc hiểu hai nhánh dùng cùng view.	Mô tả riêng view chuẩn/view xoay; đặc tả kích thước tensor, logits và minibatch dùng cho từng loss.
Trang 3–4, mục 3.3	Contrastive/SupCon chưa quy định rõ phạm vi nhãn; mở rộng nhiều cấu hình.	Giữ E3–E6 ở phần tùy chọn; SupCon chỉ dùng D_L; ưu tiên một mở rộng sau phần chính.
Trang 4, Bảng 1	E1–E2 chưa phân biệt việc thêm nhiệm vụ phụ với mở rộng nguồn ảnh.	Bổ sung E2-L; giữ E1/E2 làm đối chứng chính và công khai giới hạn về công bằng tính toán.
Trang 4, mục 4	Cùng số epoch nhưng có Early Stopping; chưa có số lần lặp và quy tắc chọn checkpoint.	Chốt 100 epoch, ba lần lặp ghép cặp, tiêu chí validation và định nghĩa một epoch theo D_L.
Trang 2–4	Đánh giá IoT chưa nêu thiết bị hoặc điều kiện đo; loại head không làm backbone nhỏ đi đáng kể.	Tách chi phí học/suy luận; bổ sung giao thức latency và giới hạn kết luận khi chưa thử trên thiết bị đích.

Kiểm tra kỹ thuật đã thực hiện cho bản sửa: khởi tạo ResNet-18 theo mô tả trên PyTorch 2.10.0 và TorchVision 0.25.0 (CPU), kiểm tra chuỗi kích thước tensor và số tham số. Kết quả kiểm tra: 11.169.858 tham số suy luận; 11.171.910 tham số khi thêm Rotation Head. Chưa huấn luyện mô hình và chưa đo chất lượng phân loại hay latency thực nghiệm.

Các seed, hằng số Normalize, quy tắc minibatch và số lượt đo latency trong bản sửa là thiết lập được đề xuất để khép kín giao thức, không phải thông số đã được sinh viên xác nhận hoặc kết quả đã có. Giảng viên và sinh viên cần chốt chúng trước khi chạy thực nghiệm chính.